

Detecção de domínios funcionais em proteínas

Redes de contato · centralidade · detecção de comunidades (Louvain)

Passo a passo de execução · resultados do teste e do alvo 6B1T

Proteína = rede social de aminoácidos


1 **Nó:** cada resíduo de aminoácido

2 **Aresta:** dois resíduos em contato físico no espaço 3D

3 **Comunidade:** grupo coeso por dentro, esparsa por fora = domínio

Detectar domínios funcionais equivale a detectar comunidades de rede.

SYNTH: comunidades sobre a estrutura 3D



Benchmark sintético: 4 domínios plantados, recuperados pelo Louvain

Rede de contatos por resíduo (não por átomo)

Nó

1 resíduo (cadeia + nº)

Aresta

átomos pesados $\leq 5 \text{ \AA}$ (modo heavy) ou
 $C\alpha \leq 8 \text{ \AA}$ (modo ca)

Peso

nº de contatos atômicos (heavy) ou
1/distância (ca)

Por que por resíduo?

Viabilidade em escala: reduz de ~1.000.000 de átomos para ~10.000–100.000 resíduos, preservando a topologia de domínios (busca de vizinhos com KD-tree).

Distância como critério:

proximidade espacial é o substrato físico do enovelamento: resíduos do mesmo domínio se empacotam juntos.

Como rodar o projeto

1 · Instalar

```
pip install -r requirements.txt
```

2 · Validar o pipeline (testes)

```
python run_experiments.py
```

3 · Rodar o alvo 6B1T

```
python run_6b1t.py  
python derive_trimers_6b1t.py
```

4 · (opcional) anotação oficial RCSB

```
python fetch_rcsb_metadata.py 6B1T  
python run_pipeline.py --pdb 6B1T \  
  --annotation data/6B1T_annotation.csv
```

Validação em dados controlados e reais

0,92


ARI · benchmark sintético

0,84


ARI · hemoglobina (4 cadeias)

0,74 / 0,69

modularidade Q



Sintético: 4 domínios plantados recuperados (cutoff 10 Å)



Hemoglobina: 4 cadeias recuperadas ($\gamma=0,2$); revela interface $\alpha\beta_2$

Capsídeo: 12.544 resíduos, Q = 0,90

73.276

arestas


30

comunidades ($\gamma=1$)


0,89

ARI vs trímeros+pénton+menores

Requisito mínimo superado:
pénton isolado + 4 trímeros de héxon recuperados
individualmente.



As comunidades reproduzem as famílias anotadas



Héxon	4 trímeros nas 4 primeiras comunidades
Pénton	isolado em comunidade própria
Ill	auto-organiza em comunidade própria (cimento dos vértices)
IX	parte própria, parte costurada entre héxons (interlacing)
VI / VII	embutidas nos héxons que revestem por dentro

Comunidade $\approx$ domínio, na escala certa de resolução

- Pipeline calibrado (sintético ARI 0,92) e validado em multímero real (hemoglobina ARI 0,84).
- Alvo 6B1T executado: $Q = 0,90$; comunidades reproduzem 4 trímeros de héxon + pénton + menores (ARI 0,89).
- Redes de contato são grafos geométricos (grau limitado); a resolução γ deve casar com a escala do domínio.
- Reprodutível: `run_experiments.py` · `run_6b1t.py` · `fetch_rcsb_metadata.py` (anotação oficial RCSB).